


唐宋诗词的时代回响

The Echoes of an Age: Tang–Song Poetry across Two Ruptures

以两次大断裂为锚的文本计量可视化

数据可视化导论 课程项目 VisProject 中期报告



唐 · 五代 · 两宋 · 712 — 1279

组员：陈维嘉 蒋文倩 孙嘉泽

2026 年 6 月

诗

前言

唐诗与宋词是中国古典文学的两座高峰。本项目以约 7.8 万首唐诗、宋词为素材，借助文本计量与数据可视化，考察文学如何回应时代——尤其是**安史之乱（755）**与**靖康之变（1127）**两次最剧烈的历史断裂前后，文人的情感、意象、词汇与地理书写发生了怎样的变化。

我们刻意不预设“唐外向、宋内向”的单一结论，而让数据自己说话：盛唐的昂扬如何在断裂中沉潜，北宋如何转向清雅内省，而靖康之后南宋的豪放又如何回潮。本中期报告记录截至目前的项目背景、分析任务、数据处理、可视化设计方案，以及实现进展与下一步计划。

数据可视化导论 • VisProject 第 2 小组

2026 年 6 月

目录

第一章 项目背景	1
1.1 主题	1
1.2 研究立意：探索性，而非预设结论	1
1.3 为什么是 712-1279 这个跨度	1
1.4 历史分期：五期 + 两道断裂带	1
第二章 分析任务定义	3
2.1 核心研究问题	3
2.2 为什么用可视化，而非纯统计 / 机器学习	3
2.3 六个分析子任务（X 轴 = 五个有序时期）	3
2.4 取舍（明确删减，避免发散）	4
第三章 数据说明	5
3.1 数据来源	5
3.2 两个地基性事实（决定了整套处理）	5
3.3 确定性处理管道	5
3.4 时期分布（语料 78 648 首）	6
3.5 仪表盘数据契约	6
3.6 已知局限	6
第四章 设计方案	7
4.1 设计需求	7
4.2 视觉隐喻：时间长河上的“流”与“繁星”	7
4.3 技术栈	7
4.4 六屏叙事结构	8
4.5 多视图协调	8
第五章 实现进展与待完成工作	9
5.1 目前实现进展	9
5.1.1 数据处理管道（已完成并通过校验）	9
5.1.2 初步分析发现（核心结果）	9
5.1.3 文档与封面	10

5.2 待完成的工作 10

第一章 项目背景

1.1 主题

本项目以中国古典诗词为素材，覆盖公元 712 年（盛唐）至 1279 年（南宋末），跨越唐、五代、两宋，构建一个叙事型数据可视化系统，用可量化的文本证据考察文学如何回应时代变迁。

1.2 研究立意：探索性，而非预设结论

我们不预设“唐外向、宋内向”的单一结论，而是以两次最剧烈的历史断裂为锚，做探索性分析：

统领问题

中国文人在两次大断裂——安史之乱（755）、靖康之变（1127）——前后，精神世界与文学表达发生了怎样的变化？

数据已显示这并非单调的“由外向内”：唐代外向性确在下降，但靖康之变后，南宋豪放派（辛弃疾、陆游的家国激愤）使外向性回潮，与姜夔、吴文英的醇雅并存——一个断裂岔出两条路。这种“反弹”正是结论的一部分，而非噪音。

1.3 为什么是 712-1279 这个跨度

- **覆盖完整周期**：兴起—极盛—断裂—沉潜—重构—再断裂—再分化，两次“盛极而崩”互为镜像。
- **两大断裂可对照**：755 与 1127 都是“军事崩溃 + 被迫南迁 + 文学剧变”，并置可见文学回应历史的共性与差异。
- **唐诗 vs 宋词**：完成古典诗词最经典的纵向对比。
- **可验证**：每个转变都有可量化的文本证据（情感、意象、地理、词频多维同步）。

1.4 历史分期：五期 + 两道断裂带

时间轴为有序时期轴，两道断裂带分别落在 755（盛唐 | 中唐）与 1127（北宋 | 南宋）。

时期	大致时间	社会状态	文学精神
盛唐	712-755	开元盛世	昂扬、开阔、功业向往
中唐	756-835	安史之乱后、藩镇	沉郁、写实、转向内省
晚唐五代	836-960	衰乱、分裂	感伤、绮丽、向内
北宋	960-1127	统一、儒学复兴	理性、清雅、日常审美（内向最深）
南宋	1127-1279	偏安、抗金	豪放回潮 + 醇雅并存

两个人形节点：杜甫横跨安史之乱（盛唐 → 中唐），李清照横跨靖康之变（北宋 → 南宋）——分别是两次断裂亲历的“最亮的星”，将在可视化中作为接缝处的关键个案。

第二章 分析任务定义

2.1 核心研究问题

核心问题

中国文人在两次大断裂——安史之乱（755）、靖康之变（1127）——前后，精神世界与文学表达发生了怎样的变化？

这是一个探索性、可被数据验证的主问题，统一收敛到“两次断裂前后的对照”这条主轴。

2.2 为什么用可视化，而非纯统计 / 机器学习

- 1. **问题是阐释性的，而非预测性的：**要回答的不是“分类准确率多高”，而是“精神世界如何随时代迁移”，这类人文结论需专家在历史语境中解读，单一统计量无法概括。
- 2. **核心是多维度协同的时间叙事：**情感、意象、体裁、地理、词汇需在同一时间轴上同步比对，可视化的多视图协调（brushing & linking）天然适配。
- 3. **目标是发现 non-trivial pattern：**探索性分析依赖交互式追问（拖时间轴、点选意象、下钻原诗），正是可视化的 details-on-demand 优势。
- 4. **指标是代理变量，需可追溯：**情感分、外内比等都是对“精神状态”的近似度量，必须能随时下钻回原诗验证，避免把指标当真相。

2.3 六个分析子任务（X 轴 = 五个有序时期）

编号	子任务	看什么 / 主图
T1	情感演化	盛唐高 → 中晚唐低徊 → 北宋回升 → 南宋再降 / 情感温度计
T2	意象演化（核心）	外内比 = 宏/私：唐持续下降、 南宋回弹 / 意象河流图
T3	体裁演化	唐诗体裁 → 词的兴起 / 堆叠面积图
T4	地理空间	塞北西域 → 江南都市 → 偏安江南 / 诗歌地图
T5	唐宋词汇对比	唐大物象 vs 宋雅物小空间（繁简已统一） / 双色词云
T6	两大断裂断面	755 / 1127 前后对照、升降词、亲历名篇 / 断面专屏

T1、T2 为主线；**T6 两大断裂为戏剧高潮**；T4 为“诗歌地理学（Poetry GIS）”亮点。全局叠加“**流**（全集聚合，显时代面貌）/ **繁星**（三百首名篇逐首，可点击下钻）”双层。

2.4 取舍（明确删减，避免发散）

- **删除典故来源热力图**：需古汉语 NER + 古籍知识图谱，工程量巨大且准确率低。
- **删除 LLM 精确年份推断**：易幻觉；改用“有序时期 + 置信度”。
- **LLM 降为可选附件**：确定性管道为可信核心，LLM 因一致性问题默认不接入主结论。
- **有余力再做**：LDA 主题河流、诗人社交网络。

第三章 数据说明

3.1 数据来源

语料取自开源的 *chinese-poetry* 数据集。

语料	文件	字形	规模
全唐诗	poet.tang*.json	繁体	57 599 首
宋词（全宋，含南宋）	ci.song*.json	简体	21 049 首
唐作者元数据	authors.tang.json	繁体	3 663 人
宋词作者元数据	author.song.json	简体	1 529 人
名篇选集	唐诗三百首 (366)、宋词三百首 (280)	—	—

不使用：poet.song.*（是宋诗，非宋词）、authors.song.json（宋诗作者）。

3.2 两个地基性事实（决定了整套处理）

事实一：繁简割裂

唐诗为**繁体**、宋词为**简体**（实测唐诗繁/简 $\approx 5554/30$ ，宋词 $\approx 0/7304$ ）。若不统一，词频/意象的“唐宋对比”会把**繁简差异**误当**时代差异**。

事实二：逐首创作年不可恢复

唐 3663 位作者中能从传记解析真实生卒年者极少；逐首诗的精确创作年学界亦常存争议。故**时间轴只能到“时期”粒度**，不伪造逐年数据。

3.3 确定性处理管道

管道 ingest $\rightarrow$ metrics $\rightarrow$ qa（详见 pipeline/README.md），完全确定性、可复现、不依赖大模型。

- 繁简归一**：作者名与正文统一经 OpenCC 繁 $\rightarrow$ 简，统计基于简体文本，保留原文供展示。
- 定年阶梯**（不伪造年份）：唐——“诗人 $\rightarrow$ 时期”查表（高置信） $\rightarrow$ 作者传记年号推时期（中置信） $\rightarrow$ 否则“未定年”；宋词——“宋词人 $\rightarrow$ 北宋/南宋”查表 $\rightarrow$ 传记生年阈值 1085 $\rightarrow$ 否则“未定年”。未定年不进时间轴，但仍进唐宋对比、词频、意象聚合。
- 去重、空正文过滤、稳定 ID**（词无 ID 用内容哈希生成）。

4. 名气标记：是否入选三百首、是否名家、是否两大断裂亲历名篇。

3.4 时期分布（语料 78 648 首）

时期	数量	定年来源	数量
盛唐	8 870	诗人表	33 860
中唐	19 132	传记年号	9 775
晚唐五代	15 633	宋词人表	8 688
北宋	3 680	传记生年	3 047
南宋	8 055	未知（未定年）	23 278
未定年	23 278		

可入时间轴（datable）：**55 370 / 78 648 ≈ 70%**（唐诗 75%；名家名篇范围接近全可定年）。

3.5 仪表盘数据契约

时间轴为有序时期（非年份桶）。所有文件为严格 JSON。主要产物：`meta`、`sentiment_by_period`、`imagery_flow`、`genre_by_period`、`word_freq_comparison`、`place_geo`、`stars`（繁星 = 名篇逐首）、`rupture_755`/`rupture_1127`（两大断裂断面）。分析范围可切换 `full`（流）/`representative`（名家，叙事默认）/`anthology`（三百首）。

3.6 已知局限

- 情感/意象为词典法代理指标，不如人工细读精准，但确定性、可复现，且可下钻原文核对。
- 未定年约 2.3 万首（多为长尾小作者）不进时间轴；时间轴结论主要由名家名篇范围支撑。
- 三百首选集反映后世编选取向，故保留 `full` 全集范围交叉对照。
- “唐诗 vs 宋词”对比同时含“诗/词体裁”与“时代”两重差异，解读时需说明。

第四章 设计方案

4.1 设计需求

围绕核心问题，系统需满足：

- 1. **叙事性**：以时间长河为骨架，把情感、意象、体裁、地理、词汇组织成一条可被引导阅读的故事线。
- 2. **多视图协调**：各视图共享同一时期语义，支持 brushing & linking——选定一个时期，其余视图同步聚焦。
- 3. **细节按需展开**：宏观指标可下钻到具体诗作，保证代理指标可追溯回原文。
- 4. **对比性**：支持“唐 vs 宋词”纵向并置，以及两大断裂前后的断面对照。
- 5. **数据诚实**：低置信 / 未定年数据在视觉上弱化或单列，不冒充事实。

4.2 视觉隐喻：时间长河上的“流”与“繁星”

隐喻	数据层	视觉角色
流（普通作品汇聚成时代面貌）	全集按时期聚合	连续成势的底层河水
繁星（最具代表性的名篇）	三百首名篇逐首	河面上可点击下钻的星

两道红色“断裂带”（755、1127）横切长河，标记安史之乱与靖康之变。

4.3 技术栈

React + Vite + ECharts（前端，纯静态数据，无后端）。理由：规划的图表（themeRiver、地图、词云、堆叠面积、关系图）几乎都是 ECharts 原生类型，开箱即用；数据已是静态 JSON，fetch 即用、可构建为静态包演示；组件化便于三人并行开发。

4.4 六屏叙事结构

屏	主题	主图	交互
S1	历史时间轴 + 情感温度计	折线 + 事件带	拖时间轴联动
S2	意象的生死流转（核心）	意象河流图 + 外内比	点选意象高亮
S3	诗体的新陈代谢	堆叠面积	hover 看明细
S4	地域空间（Poetry GIS）	地图 + 散点/热力	切时期看版图
S5	唐诗 vs 宋词	双色对比词云	点词下钻例句
S6	两大断裂断面	前后对照 + 升降词	切换 755 / 1127

4.5 多视图协调

S1 的时间轴是全局“指挥棒”：选定时期后，S2 河流聚焦该时段、S3 体裁高亮对应列、S4 地图切到该时期版图，实现视图间真正联动而非各自独立——这是评分中“多视图协调与交互”的核心着力点。

第五章 实现进展与待完成工作

5.1 目前实现进展

5.1.1 数据处理管道（已完成并通过校验）

已完成从原始数据集到仪表盘数据的**完整确定性管道**（`config / normalize / ingest / metrics / qa`），并对旧版做了地基级重构：

- 繁简统一**：OpenCC 繁 → 简，唐宋词频对比首次干净（不再把繁简差异误当时代差异）。
- 诚实定年**：弃用旧“作者生卒中点分 20 年桶”（被默认年份污染），改为有序时期轴 + 定年阶梯，唐诗可定年 $\approx 75\%$ 。
- 范围纠错**：发现宋词语料实为全宋词（含大量南宋），改用词人表 + 生年阈值区分北宋/南宋。

端到端校验（qa.py 全部通过）

语料 78 648 首；datable 70%；**简体文本繁体残留 = 0**；所有仪表盘 JSON 严格可解析；时期序列按盛唐 → 中唐 → 晚唐五代 → 北宋 → 南宋单调；去重与定年对账一致。

5.1.2 初步分析发现（核心结果）

确定性指标已能复现并量化核心叙事，且在 `full` 与 `representative` 两个范围下趋势一致（结论稳健）。




图 1 意象外内比（宏大意象 / 私人意象）的时代变迁

关键发现

外内比：盛唐 1.79 → 中唐 1.26 → 晚唐 1.07 → 北宋 0.57 → **南宋 0.73（回升）**。唐代“由外向内”清晰可见，北宋内向最深；而**靖康之变后南宋外向性回潮**——辛弃疾、陆游的家国激愤使“万里/西风”等宏大意象反弹。这一“反弹”是单调“外 → 内”叙事无法解释的，正是本项目最有价值的发现。




图 2 情感均值与外内比的时期对照

此外：两大断裂断面已自动产出——靖康断面中南宋升频词含“万里/西风/家国”信号，策展名篇精准命中辛弃疾《永遇乐·京口北固亭怀古》、陆游、岳飞等；唐宋独有词在繁简统一后呈清晰分野（唐“心/身/城/门/名”偏外、实，宋“东风/江南/梅花/归去/回首”偏婉约、私人）。

5.1.3 文档与封面

项目报告（背景/任务/数据/设计）、数据处理记录、pipeline/README 均已就绪；本报告主题封面（水墨时间长河 + 繁星 + 两大断裂）为自制。

5.2 待完成的工作

- 1. **前端仪表盘**：用 React + Vite + ECharts 渲染六屏叙事，落地“流 + 繁星”双层、两大断裂断面屏与诗歌地图，并实现多视图联动。
- 2. **案例展示**：待系统跑通后补充真实截图与可复现的交互路径（如下钻杜甫安史名篇、辛弃疾靖康名篇）。
- 3. **细节优化**：词频加停用词表（滤“了/是”等虚词）；宋词三百首匹配率（约 76%）改首句匹

配提升。

4. **可选增强：**LDA 主题河流、诗人社交网络（有余力再做）；LLM 作为可选附件做细腻情感类型标注。
5. **系统文档与答辩：**期末补齐设计需求/介绍/案例/AI 使用声明，准备 Demo 视频与现场演示。